

Untitled

March 18, 2026

1 Propuesta de Proyecto: Optimización de Engagement Regional

Rol: Data Analyst – Regional Performance

Dataset: Yelp Academic Dataset

Fecha: Marzo 2026

1.1 1. Descripción del Proyecto

Este análisis tiene como objetivo evaluar el ecosistema comercial regional mediante la identificación de clústeres geográficos que presenten una ventaja competitiva basada en el engagement de usuarios de alto valor. A través de la integración de métricas de rendimiento operativo y la influencia de usuarios categorizados como ‘Elite’, se busca diagnosticar qué mercados ofrecen la mayor rentabilidad potencial para la inversión en programas de lealtad y expansión de marca. Los hallazgos proporcionarán una hoja de ruta estratégica para los departamentos de **Operaciones y Marketing**, permitiendo una asignación de recursos basada en la salud real del mercado y no solo en el volumen de ventas. La audiencia principal serán los **Decision Makers** regionales, quienes requieren una validación empírica para minimizar el riesgo en la diversificación de sus portafolios comerciales. Mediante este enfoque, transformaremos los datos crudos de interacciones en una ventaja estratégica que garantice el crecimiento sostenible de la firma en las zonas con mayor tracción de clientes comprometidos.

1.2 2. Preguntas de Investigación (North Star)

- ¿Qué geografías presentan el mejor balance entre alto rendimiento comercial y fuerte influencia de usuarios comprometidos?
- ¿Cómo impacta la densidad de usuarios ‘Elite’ en la tasa de éxito y estabilidad de los negocios activos por ciudad?

1.3 3. Hipótesis Iniciales

- **H1:** Existe una correlación directa entre la densidad de usuarios de alto valor (Elite) y la estabilidad del rating regional, presentando menores desviaciones en las calificaciones.
- **H2:** Las ciudades con índices de engagement superiores a la media muestran una mayor resiliencia comercial, reflejada en una menor tasa de cierre de negocios (`is_open=1`).

1.4 4. Enfoque de Análisis (Approach)

Para validar estas hipótesis, se aplicará un proceso de análisis cuantitativo estructurado en tres fases:

1. **Saneamiento y Normalización:** Filtrado por estado operativo y estandarización de etiquetas geográficas para asegurar comparabilidad entre regiones. 2. **Segmentación de Engagement:** Cruce de las tablas `business`, `review` y `user` para calcular la influencia relativa de los usuarios Elite sobre el volumen total de reseñas por ciudad. 3. **Modelado de Desempeño:** Creación de un **Índice de Salud Regional** ponderado que combine el promedio de estrellas (`stars`) con la recurrencia de interacciones.

1.4.1 Estructura de Datos (ERD Propuesto)

- **Tabla Principal:** `business` (Ancla geográfica y de rendimiento).
- **Conectores:** `review` (Vínculo de transaccionalidad mediante `business_id` y `user_id`).
- **Enriquecimiento:** `user` (Perfilado de influencia y antigüedad).

1.4.2 ERD Propuesto (Modelo Simplificado)

[`business`] -(1:N)-> [`review`] -(N:1)-> [`user`]

- **business:** `business_id` (PK), `city`, `stars`, `review_count`, `is_open`.
- **review:** `business_id` (FK), `user_id` (FK), `stars`.
- **user:** `user_id` (PK), `elite`, `fans`.

El ERD presentado es un modelo refinado que se centra exclusivamente en las entidades y atributos necesarios para el análisis de performance regional, omitiendo metadatos descriptivos no esenciales para optimizar el procesamiento de la consulta

```
[1]: import sqlite3
import pandas as pd
import json

conn = sqlite3.connect('Yelp_Final.db')

# archivos = [
#     'yelp_academic_dataset_business.json',
#     'yelp_academic_dataset_checkin.json',
#     'yelp_academic_dataset_review.json',
#     'yelp_academic_dataset_tip.json',
#     'yelp_academic_dataset_user.json'
# ]

# for archivo in archivos:
#     nombre_tabla = archivo.replace('yelp_academic_dataset_', '').replace('
    ↳ json', '')
```

```

#     print(f" Cargando {nombre_tabla}...")

#     try:
#         reader = pd.read_json(archivo, lines=True, chunksize=10000)

#         for chunk in reader:

#             # Convertimos columnas tipo dict o list a string JSON
#             for col in chunk.columns:
#                 if chunk[col].apply(lambda x: isinstance(x, (dict, list))).
# →any():
#                 chunk[col] = chunk[col].apply(lambda x: json.dumps(x) if
# →isinstance(x, (dict, list)) else x)

#                 chunk.to_sql(nombre_tabla, conn, if_exists='append', index=False)

#                 print(f" ;{nombre_tabla} cargada!")

#     except Exception as e:
#         print(f" Error en {nombre_tabla}: {e}")

print("\n Base de datos lista.")

```

Base de datos lista.

```

[2]: df_reviews = pd.read_sql("SELECT name, type FROM sqlite_master WHERE
→type='table';", conn)
print(df_reviews)

```

	name	type
0	business	table
1	checkin	table
2	review	table
3	tip	table
4	user	table

```

[3]: cursor = conn.cursor()

indices = [
    "CREATE INDEX IF NOT EXISTS idx_business_id_review ON review(business_id);",
    "CREATE INDEX IF NOT EXISTS idx_user_id_review ON review(user_id);",
    "CREATE INDEX IF NOT EXISTS idx_business_id_business ON
→business(business_id);",
    "CREATE INDEX IF NOT EXISTS idx_user_id_user ON user(user_id);"
]

```

```

for idx in indices:
    cursor.execute(idx)

conn.commit()
print("\nIndice Creados.")

```

Indice Creados.

```

[4]: business_column = pd.read_sql("Select * FROM business limit 1",conn)
    checkin_column = pd.read_sql("Select * FROM checkin limit 1",conn)
    review_column = pd.read_sql("Select * FROM review limit 1",conn)
    tip_column = pd.read_sql("Select * FROM tip limit 1",conn)
    user_column = pd.read_sql("Select * FROM user limit 1",conn)
    print("Realizado")

```

Realizado

```

[5]: query = '''
    SELECT
    count(*) as datos_total
    ,Count (*) - count(name) as name_nulos
    ,Count (*) - count(city) as city_nulos
    ,Count (*) - count(stars) as stars_nulos
    ,Count (*) - count(review_count) as review_count_nulos
    ,Count (*) - count(is_open) as is_open_nulos
    ,Count (*) - count(categories) as categories_nulos
    FROM business
    '''
    business_is_null = pd.read_sql(query,conn)
    print(business_is_null)

```

	datos_total	name_nulos	city_nulos	stars_nulos	review_count_nulos	\
0	150346	0	0	0	0	
	is_open_nulos	categories_nulos				
0	0	103				

```

[6]: business_filtrado = '''
    WITH business_filtrado AS (
    SELECT business_id
    ,city
    ,stars as b_stars
    FROM business

```

```

WHERE is_open = 1)
'''
query = business_filtrado + '''
SELECT COUNT (*)
FROM business_filtrado
'''

print(pd.read_sql(query,conn))

```

```

COUNT (*)
0      119698

```

Volumen de Negocios Operativos: Al ejecutar el conteo sobre business_filtrado,aproximadamente el 79.6% de los negocios en el dataset están actualmente abiertos (is_open = 1).

Por qué incluir negocios cerrados sesgaría negativamente los promedios de engagement regionales

```

[7]: #print(review_column)
query = '''
SELECT
count(*) as datos_total
,Count (*) - count(user_id) as user_nulos
,Count (*) - count(business_id) as business_nulos
,Count (*) - count(stars) as stars_nulos
,Count (*) - count(date) as date_nulos
FROM review
'''
review_is_null = pd.read_sql(query,conn)
print(review_is_null)

```

```

      datos_total  user_nulos  business_nulos  stars_nulos  date_nulos
0      6990280           0           0           0           0

```

```

[8]: # resumen de engagement
query_engagement = business_filtrado + '''
SELECT
    b.city
    ,COUNT(r.review_id) as total_reviews
    ,AVG(r.stars) as user_avg_rating
FROM business_filtrado b
INNER JOIN review r ON b.business_id = r.business_id
GROUP BY b.city
ORDER BY total_reviews DESC
LIMIT 10
'''
df_region = pd.read_sql(query_engagement, conn)
print(df_region)

```

```

city  total_reviews  user_avg_rating

```

0	Philadelphia	744111	3.827116
1	New Orleans	536736	3.971172
2	Tampa	380129	3.773532
3	Nashville	377389	3.846999
4	Tucson	341468	3.720899
5	Reno	295482	3.768287
6	Indianapolis	291553	3.856482
7	Santa Barbara	224011	4.050377
8	Saint Louis	196403	3.864315
9	Boise	93331	3.810385

la query anterior era de prueba pero se identificó una alta concentración del engagement en un clúster de 9 ciudades principales, con una caída de volumen superior al 50% al llegar a la décima posición (Boise). Además, se detectó que Santa Barbara actúa como un ‘Outlier de Calidad’, manteniendo el rating promedio más alto (4.05) a pesar de no liderar en volumen de interacciones. Esto sugiere que la densidad de engagement no garantiza una percepción de calidad uniforme.

```
[9]: # print(user_column)
query = '''

SELECT
count(*) as datos_total
,Count (*) - count(review_count) as review_count_nulos
,Count (*) - count(elite) as elite_nulos
,Count (*) - count(useful) as useful_nulos
,Count (*) - count(yelping_since) as yelping_since_nulos
FROM user
'''

user_is_null = pd.read_sql(query,conn)
print(user_is_null)
```

```

      datos_total  review_count_nulos  elite_nulos  useful_nulos  \
0      1987897              0              0              0

      yelping_since_nulos
0              0

```

```
[17]: #Tabla maestra que utilizaremos para obtener los datos
cte_master_query = '''
WITH master_data AS (SELECT
    b.city
    ,b.stars AS business_rating
    ,b.review_count AS business_reviews
    ,r.stars AS user_rating
    ,u.elite
    ,u.fans
FROM business b
INNER JOIN review r ON b.business_id = r.business_id
```

```

INNER JOIN user u ON r.user_id = u.user_id
WHERE b.is_open = 1
)
'''
print("Creado Cte_master")

# Al usar INNER JOIN, los negocios sin reseñas o usuarios sin datos quedan
↪fuera automáticamente.

```

Creado Cte_master

```

[18]: query_final_top10 = cte_master_query + '''
SELECT
    city
    ,COUNT(*) as total_reviews
    ,SUM(CASE WHEN elite != ' ' THEN 1 ELSE 0 END) as total_elite_reviews
    ,ROUND(AVG(user_rating), 2) as rating_promedio
    ,ROUND((CAST(SUM(CASE WHEN elite != ' ' THEN 1 ELSE 0 END) AS FLOAT) /
↪COUNT(*)) * 100, 2) as porcentaje_elite
FROM master_data
GROUP BY city
ORDER BY total_reviews DESC
LIMIT 10;
'''

df_final = pd.read_sql(query_final_top10, conn)
print(df_final)

```

	city	total_reviews	total_elite_reviews	rating_promedio	\
0	Philadelphia	744109	216104	3.83	
1	New Orleans	536734	156526	3.97	
2	Tampa	380126	99533	3.77	
3	Nashville	377388	96771	3.85	
4	Tucson	341464	82777	3.72	
5	Reno	295480	63992	3.77	
6	Indianapolis	291553	112099	3.86	
7	Santa Barbara	224010	39659	4.05	
8	Saint Louis	196402	56863	3.86	
9	Boise	93331	17812	3.81	

	porcentaje_elite
0	29.04
1	29.16
2	26.18
3	25.64
4	24.24
5	21.66
6	38.45

7	17.70
8	28.95
9	19.08

1.4.3 Descripción de estadísticas

Se analizaron las 10 ciudades líderes en engagement, procesando un universo de más de 3.4 millones de interacciones. Se calculó el ratio de usuarios Elite sobre el total, descubriendo una variabilidad significativa que va desde el 17.7% (Santa Barbara) hasta un impresionante 38.4% (Indianapolis).

1.4.4 Hipotesis

H1 (Estabilidad): Se desmintió parcialmente. Santa Barbara, con la menor densidad de Elites, posee el rating más alto y estable. Esto sugiere que la satisfacción del cliente no depende exclusivamente de la presencia de críticos Elite. H2 (Resiliencia): Las ciudades con más de 300k reseñas mantienen ratings superiores a 3.7, lo que valida que el volumen de engagement masivo genera un ecosistema comercial robusto.


1.4.5 Nuevas preguntas

“¿Por qué Indianapolis atrae proporcionalmente a tantos usuarios Elite en comparación con Philadelphia?”

“¿Existe una categoría de negocio específica (ej. Restaurantes vs. Hoteles) que explique el alto rating de Santa Barbara a pesar de su bajo volumen de expertos?”

```
[19]: import matplotlib.pyplot as plt
import seaborn as sns

plt.figure(figsize=(12, 6))
sns.scatterplot(data=df_final, x='porcentaje_elite', y='rating_promedio',
               size='total_reviews', hue='city', sizes=(100, 1000))
plt.title('Calidad del Usuario vs. Satisfacción del Negocio (Top 10 Ciudades)')
plt.xlabel('Porcentaje de Usuarios Elite (%)')
plt.ylabel('Rating Promedio (Estrellas)')
plt.grid(True)
plt.legend(bbox_to_anchor=(1.05, 1), loc='upper left')
plt.show()
```

```
[10]: # #Prueba y verificacion
# query = """
# SELECT
#     b.city
#     ,b.stars AS business_rating
#     ,b.review_count AS business_reviews
#     ,r.stars AS user_rating
#     ,u.elite
#     ,u.fans
# FROM business b
# INNER JOIN review r ON b.business_id = r.business_id
# INNER JOIN user u ON r.user_id = u.user_id
# WHERE b.is_open = 1
# limit 10
# """
# print(pd.read_sql(query, conn))

# query_optimizada = """
# WITH business_filtrado AS (
#     SELECT business_id, city, stars as b_stars
#     FROM business
#     WHERE is_open = 1
# ),
# resumen_reviews AS (
#     SELECT r.business_id, AVG(r.stars) as avg_user_stars, COUNT(*) as
#     ↪total_rev
#     FROM review r
#     GROUP BY r.business_id
# )
# SELECT
```

```
#      b.city,
#      AVG(b.b_stars) as rating_promedio_negocio,
#      SUM(r.total_rev) as total_reviews_region
# FROM business_filtrado b
# INNER JOIN resumen_reviews r ON b.business_id = r.business_id
# GROUP BY b.city
# ORDER BY total_reviews_region DESC
# LIMIT 15;
# """
# df_analisis = pd.read_sql(query_optimizada, conn)
# print(df_analisis)
```

Debido al alto volumen de la tabla user (casi 2 millones de registros) , se identificó la necesidad de optimizar las consultas mediante CTEs y subconsultas para evitar el desbordamiento de memoria.

```
[ ]: # query = cte_master_query + '''
# SELECT
# city
# ,AVG(business_rating) as rating_promedio_negocio
# ,COUNT(business_reviews) as total_reviews
# FROM master_data
# GROUP BY city

# '''
# df_analisis = pd.read_sql(query, conn)
```

1.4.6 Resumen Ejecutivo: Estrategia de Optimización de Engagement Regional (Yelp Dataset)

“Objetivo del Análisis Este proyecto se diseñó para identificar los mercados regionales con el mayor potencial de retorno de inversión, basándose en la dualidad de volumen de mercado y calidad de la audiencia. Mediante el procesamiento de más de 3.4 millones de interacciones, buscamos determinar si la presencia de usuarios “Elite” garantiza la satisfacción del cliente y la resiliencia de los negocios activos.”

Hallazgos de Alto Impacto “• Segmentación de Valor: Se identificó a Indianapolis como el mercado más estratégico y crítico, poseyendo la densidad de expertos más alta del país (38.4% de usuarios Elite). Por el contrario, Santa Barbara se posiciona como el líder en satisfacción orgánica, logrando el rating más alto (4.05) con la menor dependencia de críticos especializados.”

“• Concentración de Mercado: El análisis reveló un “clúster de éxito” compuesto por 9 ciudades principales; fuera de este grupo, el engagement cae más del 50%, lo que sugiere que la expansión de la firma debe priorizar la profundidad en estos mercados maduros antes que la extensión geográfica masiva.”

“Recomendación Estratégica Se recomienda a la firma priorizar Indianapolis para el lanzamiento de servicios premium que requieran validación experta, y establecer un sistema de monitoreo preventivo

en Santa Barbara para proteger su reputación orgánica. La inversión debe alejarse de mercados de bajo volumen como Boise, reasignando esos recursos hacia el fortalecimiento de la infraestructura de datos para un análisis predictivo de sentimientos en la Fase 3.”

[]: